

DAH 2026

Defense AI Cyber Security Hackathon

예선 보고서

방산 AI 공격·방어

에이전트 설계 및 검증

PX4 기반 UAV 군집 환경에서의 MAVLink 공방전 아키텍처

팀명

TPQ74-K

팀원

전상록 · 임재현 · 신종규 · 표재경

목차

1. 팀 구성 및 역할 분배	6
1-1. 팀원 구성 및 역할	6
1-2. 역할 시너지	7
2. 방산 분야 공격 시나리오 설계	8
2-1. 위협 환경 및 설계 관점	8
2-2. 공격 목표 및 전술적 가정	9
2-3. 자율 공격 에이전트 구조 및 실행 흐름	10
3. 공격 시나리오 대응 방어 아키텍처 수립	14
3-1. 방어 설계 관점	14
3-2. 방어 에이전트 설계 원칙	14
3-3. 방어 대응 흐름	15
4. AI 에이전트 아키텍처 및 구현	16
4-1. AI 에이전트 전체 아키텍처	16
4-2. 공격 AI 에이전트 설계	17
4-3. 방어 AI 에이전트 설계	21
5. 시나리오 구현 및 검증 증적	27
5-1. 공격 시나리오 구현 증적	29
5-2. AI 방어 시나리오 구현 증적	31
6. 결론 및 향후 계획	34
6-1. 결론	34
6-2. 향후 계획	35
7. 참고문헌	36

표 목차

1-1-1. 팀원 구성 및 역할	6
2-1-1. 예선·본선 공통 실행 환경	8
2-2-1. 공격 계층별 전술적 의미와 평가 기준	9
2-3-1. 공격 에이전트 구성 단계 (OODA 매핑)	10
2-3-2. MAVLink 포트 탐색 우선순위	11
2-3-3. SET_MODE 모드별 의미와 공격 관측점	11
2-3-4. 시나리오 및 CVE 기반 공격 패턴	12
3-2-1. 방어 에이전트 구성 요소	14
3-3-1. 방어 대응 흐름 단계	15
4-1-1. AI 에이전트 역할 분리 및 통제 장치	16
4-2-1. Reconnaissance Module	17
4-2-2. MAVLinkParser / FeatureExtractor	18
4-2-3. ContextBuilder / LLMBrain	18
4-2-4. PolicyGuard	19
4-2-5. ActionTranslator / Executor	19
4-2-6. FeedbackEvaluator / AdaptiveReplanner	20
4-3-1. 관측 계층 구성요소	22
4-3-2. 판단 계층 — ReAct Analyzer	22
4-3-3. 판단 계층 — Sonnet Commander	22
4-3-4. 판단 계층 — Opus Auditor	23
4-3-5. 집행 계층 — Policy Engine	24
4-3-6. 집행 계층 — Recovery Manager	24
4-3-7. 정책 점수 체계	25
4-3-8. 대응 기준	25
4-3-9. 관측 계층 실측 요약	27
4-3-10. 아키텍처 검증 결과 요약	27
6-2-1. 향후 계획 및 우선순위	35

그림 목차

그림 1. 공방전 구성도 (Attack Agent → Bridge/PacketCache → Inline Gateway/Approval → PX4)....	7
그림 2. 공격 에이전트 3계층 구조 (관측·정찰 → 판단·정책검증 → 실행·피드백)	17
그림 3. 방어 에이전트 4계층 구조 (입력 보호·관측 → 동기 판정 → 승인·집행 → 복구·증적)	21
그림 4. 공격 성공 - 대상 및 포트 선택.....	29
그림 5. 공격 성공 - 공격 에이전트 실행 중 로그	29
그림 6. 공격 성공 - 공격 에이전트 실행 후 로그	30
그림 7. 복구 - UAV 안전 상태 전환 증적.....	31
그림 8. 허니팟 - Decoy 접근 및 탐지 로그	31
그림 9. 공격 실행 화면 - Ping_DoS 시나리오 실행 로그	32
그림 10. 탐지→판정→iptables 차단 로그	32
그림 11. 방어 에이전트 대시보드 탐지 현황	33
그림 12. 실제 iptables DROP 규칙 확인.....	33

종합 요약

최근 전장은 드론을 단순 정찰 자산이 아니라 통신, 센서, 타격, 전자전, AI 판단이 결합된 분산형 전력으로 운용하는 방향으로 빠르게 변화하고 있다. 우크라이나 전쟁 사례에서도 드론은 전방 정찰을 넘어 보급선, 에너지 기반 시설, 지휘·통제 흐름을 압박하는 수단으로 확대되고 있으며, 이에 대응하는 전자전·대드론·기동 방어 기술도 동시에 고도화되고 있다. 이러한 변화는 UAV의 기체 성능뿐 아니라 MAVLink/C2 링크, 텔레메트리 신뢰성, 임무 명령의 무결성, AI 판단 계층의 안전성이 임무 지속성을 좌우한다는 점을 보여준다. [33], [34], [35]

본 보고서는 PX4 기반 UAV 군집 운용 환경을 대상으로, LLM 판단기반 공격 에이전트와 AI 방어 에이전트가 실제 MAVLink 패킷, 기체 상태 변화, 방어 로그를 근거로 상호작용하는 대응 전략을 정리한 문서이다. 본 팀 TPQ74-K는 단순한 취약점 나열이나 개별 공격 성공 여부에 그치지 않고, 정상 임무 중 발생할 수 있는 MAVLink 제어·텔레메트리 계층의 이상 행위와 이에 대한 AI 기반 탐지·판단·대응 체계를 함께 설계하는 데 중점을 두었다. [1], [2]

본 시나리오의 핵심 위협은 UAV, 지상 통제 시스템, MAVLink 통신, 텔레메트리 데이터, AI 의사결정 계층이 연결된 환경에서 발생하는 복합 이상 행위이다. 공격 에이전트는 MAVLink의 주기적 HEARTBEAT와 상태 메시지 노출 가능성을 고려하여 먼저 수동 관측을 수행하고, 정보가 부족한 경우 제한된 능동 정찰로 전환한다. 이후 관측된 기체 상태와 응답 결과를 기반으로 모드 변경, 명령 주입, 임무 흐름 교란, 재전송, 비인가 GCS, 텔레메트리 요청 이상, AI 판단 경계 검증(프롬프트 카나리) 등 후속 공격 시나리오를 선택한다. [7], [8], [9], [10], [22], [23]

방어 전략은 모든 외부 MAVLink 입력과 운영 로그를 무조건 신뢰하지 않는다는 전제에서 출발한다. 네트워크 패킷, MAVLink 메시지, 기체 상태, 텔레메트리 데이터, AI 판단 로그를 분리된 계층에서 검증하고, 단일 탐지 결과가 즉시 고위험 차단으로 이어지지 않도록 설계하였다. Suricata 기반 패킷 탐지, Rule Engine, MAVLink Runtime Monitor, XGBoost-MetaDetect 기반 이상 판단, Policy Engine을 결합하여 탐지·판단·차단·복구 절차가 단계적으로 수행되도록 구성하였다. [3], [4], [5], [6]

AI 에이전트 아키텍처에서는 LLM을 최종 차단자나 단독 실행 주체로 두지 않았다. LLM은 관측된 패킷과 로그를 해석하고 후보 행동 또는 판단 근거를 생성하는 보조 계층으로 활용되며, 실제 공격 실행과 방어 대응은 정책 검증 계층, 룰 기반 모듈, 정책 엔진이 통제한다. 이를 통해 AI 오판이나 환각이 즉시 운영 체계의 위험 행동으로 이어지지 않도록 하였으며, 방산 무인체계 환경에서 요구되는 견고성과 설명 가능성을 확보하고자 하였다.

본 팀 TPQ74-K는 공격 서버와 방어 서버를 분리한 클라우드 기반 공방전 환경을 구성하고, 정상 임무 로그, 공격 실행 로그, pcap, Suricata 탐지 결과, 정책 엔진 대응 결과를 증적으로 남기는 구조를 설계하였다. 또한 GitLab을 기반으로 코드, 실행 방법, 테스트 결과, 보고서 증적을 관리하여 구현 결과의 재현성과 제출 완성도를 확보한다.

1. 팀 구성 및 역할 분배

1-1. 팀원 구성 및 역할

1-1-1. 팀원 구성 및 역할

이름	전문 분야	역할	주요 경험
전상록	모의해킹 / 취약점 진단 / 보안 솔루션 엔지니어	팀장 / 공격 시나리오 설계 / Suricata 룰 구성 / 보고서 구조 설계 / 리커버리 설계 /	SK실더스 화이트해커 과정 1위 / 공공기관 취약점진단 / APEC 보안 장비 구축·운영
임재현	취약점 분석 / AI 분석 / 온프레임, 클라우드 운영 / TPQ-74K 교관	클라우드 인프라 구축 / 방어 시나리오 총괄 / 방산 모의환경 설계 / 공방전 환경 구성	Azure, AWS 보안 운영 / 통신사 침해 분석 대응 / AI분석 WEB 비지도 담당 / EDR 분석 / TPQ-74K 교관
신종규	취약점 진단 / 실시간 위협 탐지 / 보안 운영 / 개발	AI 에이전트 구현 / 탐지 파이프라인 개발 / 탐지 로그 체계 구현 / 허니팟 설계 / 테스트 환경 구축	정보보안 위협 탐지·차단 / WEB 개발 / 정보보안실태평가 점검 및 조치 (산림청,주택도시보증공사)
표재경	침해 사고 대응 / 악성 코드 분석	방어 전략 수립 / 침해사고 대응 절차 검토 / 복구 전략 설계 / 공격 시나리오 설계	NCSC 협동 분석관 / 공공·민간 침해 사고 대응· 악성 코드 분석
공통	AI 공방전 기획 / 방산 모의환경 검증	공격·방어 시나리오 검토 / 공격·방어 테스트 로그 분석 / UAV 시뮬레이션 진행 탐지·차단 결과 검증 보고서 정리 / 체크리스트 작성 / GitLab 산출물 정리	공방전 환경 검증 / AI 에이전트 결과 리뷰 / 탐지·차단 결과 공동 리뷰

1-2. 역할 시너지


본 팀 TPQ74-K의 강점은 공격 시나리오 설계, 방어 파이프라인 구현, 클라우드 공방전 환경 구성, AI 에이전트 설계 역량이 하나의 실험 흐름으로 연결된다는 점에 있다. 각 담당 영역은 개별 산출물 작성에 그치지 않고, 정상 임무 관측 → 공격 판단 → MAVLink 액션 실행 → 탐지 → 차단 → 복구 → 증적 수집으로 이어지는 end-to-end AI 공방전 구조를 구성한다.[13], [14], [15], [16], [18]

- 공격 시나리오와 방어 전략을 동일한 MAVLink 기반 공방전 흐름으로 설계하여 탐지·차단·복구 절차가 자연스럽게 연결되도록 구성함
- 클라우드 환경에서 공격 서버와 방어 서버를 분리하여 실제 공격 에이전트와 방어 에이전트가 독립적으로 동작하는 구조를 재현함
- PX4 기반 UAV 군집, QGroundControl, MAVLink 포트 구조, 정상 임무 흐름을 반영하여 실험 환경의 현실성을 확보함
- 모의해킹, 취약점 진단, 실시간 위협 탐지, 침해사고 대응 역량을 결합하여 공격 성공 여부뿐 아니라 임무 영향도와 복구 가능성까지 평가함
- 방어 에이전트의 탐지·판단·대응 과정과 Suricata를 매칭, 정책 엔진 판단, 차단·복구 결과를 증적으로 남김
- GitLab 기반으로 코드, 실행 로그, 테스트 결과, 보고서 증적을 관리하여 구현 결과의 재현성과 제출 완성도를 확보함

따라서 본 팀 TPQ74-K는 단순히 공격 성공 여부만을 제시하는 데 그치지 않고, 정상 임무 상태에서 공격 영향이 어떻게 발생하고 방어 체계가 이를 어떻게 탐지·판단·대응·복구하는지를 함께 제시할 수 있다. 이는 공격 시나리오 설계, 방어 전략 수립, AI 에이전트 아키텍처 구현이 하나의 검증 가능한 실험 체계로 연결되어 있음을 보여준다.

그림 1. 공방전 구성도 (Attack Agent → Bridge/PacketCache → Inline Gateway/Approval → PX4)

현재 공방전 운영 경로 — 공격 입력부터 PX4 전달·차단·증적까지



2. 방산 분야 공격 시나리오 설계

2-1. 위협 환경 및 설계 관점

본 팀 TPQ74-K의 공격 시나리오는 PX4 기반 다중 UAV 군집 환경에서 MAVLink 제어 및 텔레메트리 계층의 이상 행위가 방어 체계의 탐지, 격리, 복구 판단으로 어떻게 연결되는지를 검증하기 위해 설계되었다. 공격 대상은 준비한 클라우드 서버와 PX4 SITL 기반 가상 UAV 환경으로 한정하였다. 본 시나리오는 MAVLink 프로토콜과 임무 수행 상태에서 발생하는 이상 징후를 실제 패킷, 로그, 상태 변화로 관측 가능하게 만드는 데 목적이 있다. 실제 검증에서는 SET_MODE 기반 비행 모드 전환으로 임무 중인 UAV의 경로 이동이 중단되는 현상을 QGroundControl과 PX4 로그에서 확인하였다.[1], [2]

공격 에이전트는 MAVLink의 브로드캐스트 및 응답 특성을 고려하여 먼저 수동 관측을 수행하고, HEARTBEAT와 주요 상태 메시지가 충분히 확보되지 않을 경우 제한된 능동 정찰로 전환하도록 설계하였다. 이후 관측된 기체 식별자, 텔레메트리 상태, 명령 응답, 포트 반응을 바탕으로 지역 LLM이 다음 후보 행동을 판단하고, 실행 전 정책 검증 계층에서 대회 범위와 반복 제한을 확인한다. 따라서 본 팀의 공격 체계는 단순 패킷 송신 도구가 아니라, 관측, 판단, 실행, 검증, 피드백, 재계획을 반복하는 통제형 AI 에이전트로 정의된다.

또한 공격 과정에서 수집된 포트 탐색 결과, LLM 판단 근거, 송신된 MAVLink 프레임, 수신 응답, 비행 모드 전환 성공 여부, 후속 시나리오 실행 여부는 구조화된 로그로 저장하고, 실행 종료 후 사람이 검토 가능한 Markdown 형식의 증적 요약으로 정리할 수 있도록 한다. 이를 통해 공격 결과를 단순 콘솔 로그가 아니라 PX4 상태 변화, 방어 서버 패킷 캡처, QGC 관측 결과와 대조 가능한 검증 자료로 남긴다.

2-1-1. 실행 환경 — 시뮬레이션·통신·공격 서버·증적 기준

구분	세부 구성	공격 시나리오상 의미
시뮬레이션 환경	PX4 SITL, jMAVSim, Gazebo, QGroundControl	정상 임무를 수행 중인 무인체계에 대해 공격 전후의 임무 상태 변화를 관측 가능한 형태로 재현한다.
통신 계층	MAVLink 기반 제어·텔레메트리 통신	HEARTBEAT, 상태 메시지, 명령 응답, 모드 전환 메시지를 통해 기체 식별과 이상 행위 여부를 판단한다.
공격 서버	Python 기반 자율 공격 에이전트+LLM 정책 판단	수동 관측, 능동 정찰, 정책 판단, 안전 검증, 실행, 피드백 평가를 반복하며 다음 공격 행동을 선택한다.
증적 기준	공격 로그, 방어 로그, PX4/QGC 상태 변화	문자열 표식이 아니라 실제 MAVLink 패킷, 공격·방어 로그, PX4/QGC 상태 변화를 근거로 공격 영향과 방어 반응을 검증한다.

2-2. 공격 목표 및 전술적 가정

공격 목표는 기체 탈취나 물리 피해가 아니라, 허가된 방어 서버 범위 안에서 비인가 MAVLink 제어·텔레메트리 패턴에 대한 탐지와 대응을 검증하는 것이다. PolicyGuard는 대상·액션·반복·위험도·비행 모드를 검사하지만, 제출 기본 설정에서는 require_observed_sys_id와 mode_change_requires_observed_heartbeat가 false이고 control_validation도 비활성이다. 실행 전에는 ALLOWED_TARGET_IPS를 실제 허가 대상에 고정하고 두 관측 검증 옵션을 활성화한 별도 대회 프로파일을 사용해야 한다.

시나리오는 정상 임무가 먼저 수행된다는 전제에서 출발한다. 공격 서버는 지정된 방어 서버와 MAVLink 포트 후보를 대상으로 먼저 수동 관측을 수행하고, HEARTBEAT 또는 상태 메시지가 충분히 확보되지 않을 때만 제한된 능동 정찰을 수행한다. 이 과정에서 관측 가능한 MAVLink 메시지를 기반으로 기체의 시스템 식별자, 컴포넌트 식별자, 비행 모드, 텔레메트리 상태를 추출하고, 능동 정찰 단계에서는 응답 여부, 응답 지연, COMMAND_ACK 수신 여부, 명령 거부 결과, 필터링 가능성을 함께 평가한다.

2-2-1. 공격 계층별 전술적 의미 — 통신/링크·텔레메트리·제어/모드·시나리오

계층	공격 행위
통신/링크	지정 포트 대상 HEARTBEAT 수신 우선, 부족 시 제한된 능동 정찰(probe) 수행
텔레메트리	상태 메시지 요청 빈도·순서를 정상 QGC 요청 패턴과 다르게 구성
제어/모드	SET_MODE 기반 비행 모드 전환 시도
시나리오	COMMAND_LONG, MISSION_START, 반복 HEARTBEAT, 상태 요청 burst 중 1개 선택 실행

2-3. 자율 공격 에이전트 구조 및 실행 흐름

공격 에이전트는 각 실행 주기마다 정찰, 파싱, 특징 추출, 상황 구성, 정책 판단, 정책 검증, 실행 변환, 명령 수행, 피드백 평가, 이력 저장, 재계획을 순차적으로 수행한다. LLM은 최종 실행자가 아니라 현재 관측값을 해석하여 후보 행동을 제안하는 계층으로 사용된다. 실제 실행 가능 여부는 정책 검증 계층이 별도로 판단하므로, 자율성과 안전 통제가 분리된다.

2-3-1. 공격 에이전트 구성 단계 (OODA 매핑) — 관측→정찰 보완→상황 구성→판단→검증→실행/평가

단계	역할(입력)	공격 증적
1. 관측 (Observe)	HEARTBEAT와 상태 메시지를 우선 수집한다. (입력: 지정 포트 후보, passive timeout 설정)	기초 MAVLink 관측값
2. 정찰 보완	수동 관측이 부족하면 제한된 probe로 응답성을 확인한다. (입력: active recon 설정, 부족한 관측 항목)	응답 유무, 명령 응답, 지연 시간
3. 상황 구성 (Orient)	기체 식별자, 모드, 텔레메트리, 직전 결과를 하나의 판단 문맥으로 정리한다. (입력: raw packet, active recon 결과, memory)	LLM/fallback 판단 입력(target identity, telemetry state, feedback state)
4. 정책 판단 (Decide)	현재 상태에 맞는 후보 행동을 1개 선택한다. (입력: 특징 벡터, 실패 이력, 허용 액션 목록)	후보 액션, 판단 근거, 위험도
5. 정책 검증	허용 범위, 반복 제한, 비행 모드, 위험도를 검증한다. (입력: decision, context, memory, 허용 범위 설정)	allowed 또는 blocked_replaced 판정
6. 실행/평가 (Act-Evaluate)	승인된 MAVLink 액션만 송신하고 결과를 평가한다. (입력: 검증된 decision)	성공, 실패, 불확실 판정 및 다음 단계

출처: [15] Hierarchical Observe-Orient-Decide-Act Enabled UAV Swarms in Uncertain Environments

PX4 SITL 포트는 송수신 방향과 인스턴스 오프셋을 구분해 확인한다. 다중 기체의 Offboard API 원격 포트는 $14540+N$ (예: 인스턴스 0~3은 14540~14543), QGroundControl의 기본 원격 수신 포트는 14550이다. PX4 측 로컬 수신 포트는 GCS 링크가 $18570+N$, Offboard/API 링크가 $14580+N$ 이다. 4560/TCP는 시뮬레이터가 수신하고 PX4가 접속하는 전용 링크이므로, 배포 구성이 별도로 노출하지 않는 한 일반 MAVLink 탐색 대상에서 제외한다.[25]

2-3-2. MAVLink 포트 탐색 우선순위 — PX4 SITL 기반 탐색 순서

우선순위	포트/범위	문서상 의미
1	14540~14543/UDP	Offboard API 원격 수신 포트(인스턴스 0~3, $14540+N$)
2	14550/UDP	QGroundControl 기본 원격 수신 포트(PX4가 QGC로 송신)
3	18570~18573/UDP	PX4 GCS 링크 로컬 수신 포트(인스턴스 0~3, $18570+N$)
4	14580~14583/UDP	PX4 Offboard/API 링크 로컬 수신 포트(인스턴스 0~3, $14580+N$)
별도	4560/TCP	Simulator 로컬 수신 포트(PX4가 접속, 일반 MAVLink 탐색 대상 아님)

출처: [25] Default MAVLink UDP Ports

SET_MODE는 본 공격 시나리오의 핵심 검증 지점이다. 공격 에이전트는 관측된 MAVLink 상태와 임무 문맥을 바탕으로 모드 전환 필요성을 판단하고, LAND, RTL, LOITER/HOLD, AUTO/MISSION, OFFBOARD 계열 전환이 임무 상태에 미치는 영향을 관측한다.[1], [2]

2-3-3. SET_MODE 모드별 의미와 공격 관측점 — 5개 표준 PX4 비행 모드

모드	공격 관측점
LAND	임무 중인 UAV의 비행 지속성이 중단되는지 확인한다.
RTL	복귀 명령 수용 여부와 임무 이탈 가능성을 확인한다.
LOITER/HOLD	현재 위치 대기 전환으로 임무 흐름이 정지되는지 확인한다.
AUTO/MISSION	자동 임무 수행 상태에서 모드 전환과 임무 재개 가능성을 비교한다.
OFFBOARD	외부 제어권 전환 가능성과 명령 수용 범위를 확인한다.

출처 : [2] PX4 Autopilot Documentation (Main > Flight Modes)

공격 에이전트는 일반 MAVLink 위협 시나리오로 캡처 프레임 재전송, 비인가 GCS 위장 및 반복 HEARTBEAT 전송을 수행한다. 현재 제출 폴더에는 S01~S21 실행 스크립트 21개가 모두 존재하며, 프롬프트 카나리·PX4 링크 식별·Rogue GCS·텔레메트리 조작·3종 CVE intent·링크 churn까지 포함한다. 다만 2026-07-02 동적 진단 당시 배포 경로에서는 S14/S15 파일이 확인되지 않았으므로, 현재 제출본과 당시 실행 환경의 동기화 후 21개 전 시나리오 회귀시험이 필요하다. [1], [22], [23], [30], [31], [32]

2-3-4. 시나리오 및 CVE 기반 공격 패턴 — 시나리오/CVE 기반 공격 패턴

시나리오	전술적 의미	공격 로그·증적
명령 주입 검증	비인가 명령이 제어 계층에 도달할 수 있는지 확인한다.	COMMAND_LONG 및 명령 응답
임무 흐름 교란	임무 중 복귀 또는 임무 시작 명령이 상태 변화를 유발하는지 확인한다.	MISSION_START, RTL 전환, HEARTBEAT 변화
재전송/비인가 GCS	반복 HEARTBEAT와 GCS 유사 송신원을 통해 식별 혼선을 검증한다.	반복 HEARTBEAT, 송신원 IP/포트
텔레메트리 조작징후	상태 요청의 빈도와 순서가 방어 모델에 어떻게 반영되는지 확인한다.	REQUEST_MESSAGE burst, 상태 메시지 응답
CVE 기반 공격	코드 내부에 등록된 CVE-2026-32724, CVE-2026-32709, CVE-2026-1579 기준으로, 대회 지정 PX4 SITL/클라우드 표적에 한정해 프로토콜 수준 상호작용을 실행한다	검증 프레임, COMMAND_ACK 또는 상태 변화
AI 의사결정 경계 공격	MAVLink STATUSTEXT에 지시문 형태 문자열 (mavlink_prompt_canary)을 주입해 방어 LLM이 텔레메트리 텍스트를 명령으로 오인하는지 검증한다. MITRE ATLAS AML.T0051/T0054에 대응한다.	STATUSTEXT canary 수신 여부, LLM 응답의 지시 수용 여부
링크 정체성·GCS 처프 프로빙	px4_link_identity_probe와 px4_gcs_link_churn을 통해 GCS 유사 HEARTBEAT/PING/STATUSTEXT를 다중 sysid로 순환 전송하여 링크 식별 로직과 SYSID 위장 탐지 경계를 시험한다.	sysid 전환 이력, HEARTBEAT 발신원 변화

출처 : [1] MAVLink Protocol Documentation, [22] MAVSec: Securing the MAVLink Protocol for Ardupilot/PX4 Unmanned Aerial Systems, [23] MUVIDS: False MAVLink Injection Attack Detection in Unmanned Vehicles, [30] CVE-2026-32724 Detail, National Vulnerability Database, [31] CVE-2026-32709 Detail, National Vulnerability Database, [32] CVE-2026-1579 Detail, National Vulnerability Database

3. 공격 시나리오 대응 방어 아키텍처 수립

3-1. 방어 설계 관점

무인기 공방전 환경에서는 공격자가 동일한 목적을 달성하기 위해 다양한 공격 절차를 선택하거나 조합할 수 있다. 따라서 특정 공격 패턴만 정교하게 탐지하는 방식으로는 모든 상황에 대응하기 어렵다. 더욱이 실제 운용 환경에서는 탐지 정확도보다 불확실한 상황에서도 안전한 판단을 유지하는 것이 시스템의 가용성과 임무 지속성에 더 큰 영향을 미친다. 특히 방어 시스템의 오탐(False Positive)으로 정상 임무 중인 기체를 차단하는 경우, 실제 공격을 허용한 것과 유사한 수준의 임무 손실이 발생할 수 있다. 반대로 근거가 충분하지 않은 상태에서 대응을 지연하면 공격자에게 추가적인 공격 기회를 제공하게 된다. 따라서 본 시스템은 탐지 정확도를 높이는 것보다, 서로 다른 탐지 근거를 안전하게 통합하여 일관된 대응을 수행하는 것을 설계 목표로 설정하였다. [17]

이러한 목표를 달성하기 위해 본 시스템은 방어 과정을 관측(Observation), 해석(Interpretation), 집행(Enforcement)의 세 계층으로 분리하였다.

관측 계층에서는 Suricata, Rulebase, XGBoost, MAVLink Runtime Monitor, MetaDetect가 각각 서로 다른 관점에서 독립적인 탐지 근거를 생성한다. 하나의 탐지기가 우회되더라도 다른 계층에서 새로운 이상 징후를 포착할 수 있도록 다층 구조를 적용하였다.

해석 계층에서는 여러 탐지기가 생성한 근거를 종합하여 회색지대(Gray Zone) 상황을 분석하고 대응 방향을 제안한다. 이 계층에서 AI를 활용하지만, AI의 역할은 새로운 공격을 탐지하거나 차단하는 것이 아니라 이미 생성된 탐지 근거를 운영 가능한 정책으로 해석하는 것으로 한정하였다.

집행 계층에서는 AI의 제안이 아닌 Policy Engine이 최종 대응 수준을 결정한다. 차단, 복구, 정책 적용과 같은 실제 조치는 모두 결정론적 규칙에 따라 수행되며, AI는 직접 시스템을 제어하지 않는다.

추가로 관측 계층에는 MAVLink Decoy Honeypot을 추가 배치하였다. 허니팟은 PX4 제어 채널과 분리된 디코이 포트에서 UAV/MAVLink 정찰과 SSH·대시보드·Ollama 노출 탐색을 유인하고, 목적지 포트 및 MAVLink 메시지 ID를 기준으로 공격 유형을 휴리스틱 분류한다. 응답은 단순 문자열이 아니라 pymavlink 기반 MAVLink v2 바이너리 메시지로 생성되어 공격자의 반복 접근과 포트 순회를 관측하며, 이벤트는 로그와 InfluxDB에 저장된다. LLM은 가짜 상태값만 제안하고 패킷 생성은 pymavlink가 수행하므로, 허니팟은 차단자가 아닌 기만·관측 근거 생성기로 동작한다. [26], [27]

이러한 구조는 공격자가 하나의 탐지 기법을 우회하더라도 다른 관측 계층에서 새로운 근거가 생성될 수 있도록 하며, 동시에 AI의 불확실성이 실제 시스템 제어로 이어지는 것을 방지한다. [5], [6]

3-2. 방어 에이전트 설계 원칙

(1) 다층 근거 기반 관측 (Observation)

단일 탐지기의 결과만으로 대응을 결정하지 않는다. 네트워크 시그니처, 통계적 이상, 런타임 상태, 장기 패턴을 각각 독립적인 근거로 수집하고 이후 정책 단계에서 통합한다.

(2) 해석과 집행의 분리 (Interpretation & Enforcement)

AI는 관측된 근거를 해석하고 대응 방향만 제안한다. 실제 대응 수준의 결정과 차단·복구는 Policy Engine이 수행하여 AI가 직접 시스템을 제어하지 못하도록 하였다.[28], [29]

(3) 제한된 정책 적응 (Policy Adaptation)

AI가 제안한 정책 변경은 즉시 반영하지 않는다. Policy Modifier가 허용 범위, 시스템 가용성, 오탐 가능성을 검토한 이후 제한적으로 적용하며, 필요 시 이전 정책으로 자동 복원한다.

(4) Fail-safe 기반 결정론적 집행 (Resilience)

LLM 장애, 출력 오류, 통신 실패가 발생하더라도 Rulebase와 XGBoost 기반의 기존 판단 체계를 유지한다. 최종 대응은 항상 동일한 규칙에 의해 계산되어 동일한 입력에 동일한 결과를 보장한다.[24]

3-2-1. 방어 에이전트 구성 요소 — 방어 에이전트 상세 구성 요소

설계 원칙	왜 필요한가	대표 구성요소
Observation	다양한 관측 근거를 독립적으로 수집하여 오탐과 미탐을 줄인다.	Suricata, Rulebase, XGBoost, MAVLink Runtime Monitor, MetaDetect
Interpretation	회색지대(Gray Zone)의 상황을 AI가 해석하고 대응 방향을 제안한다.	Branch, ReAct, Sonnet, Opus (RAG)
Policy Adaptation	정책은 제한된 범위에서만 적응하며 시스템 안정성을 유지한다.	Policy Modifier, Rule Sandbox, Dynamic Rule
Deterministic Enforcement	최종 대응은 항상 고정된 규칙으로 결정하여 설명 가능성과 재현성을 확보한다.	Policy Engine, Recovery Manager
Fail-safe	AI 장애가 발생해도 방어 기능이 중단되지 않도록 한다.	Rulebase/XGBoost Fallback, Async Worker, Audit Log

3-3. 방어 대응 흐름

3-1의 관측·해석·집행 3계층 구조와 3-2의 설계 원칙은, 실제 공격 시나리오가 유입될 때 하나의 연속된 흐름으로 동작한다. 이는 2-3절에서 정리한 공격 에이전트의 관측→정찰→판단→실행 흐름과 대응하는 방어 측 흐름이다.

2026-07-02 async 진단에서 S02(Ping_DoS)는 Rulebase의 PING_DOS가 확인되었으나 XGBoost는 Normal(0.118)이었고, MAVLink sequence 255→0 순환을 REPLAY_ATTACK으로 오인한 신호가 HARD_BLOCK 경로에 함께 작용하였다. 따라서 당시 결과는 올바른 다층 상관탐지 성공이라기보다 오탐이 섞인 차단으로 평가한다. 현재 제출 코드에는 $expected = (last_seq + 1) \bmod 256$ 처리가 반영되어 있으므로, 수정 후 S02-S11-S13의 실제 탐지 경로를 재시험해 Rulebase·비인가 GCS 탐지만으로 의도한 대응에 수렴하는지 확인해야 한다.

3-3-1. 방어 대응 흐름 단계 — 관측→해석→정책 판단→집행→(조건부) 복구

단계	수행 내용 (입력 → 출력)	방어 증적
1. 수신·봉인	Bridge 가 GCS 명령을 가로채 원본 해시·Drone ID·방향·주소·TTL·HMAC 을 포함한 PacketEnvelope 를 만들고 PacketCache 에 PENDING 등록한다.	packet_id, packet_hash, HMAC, PENDING
2. 동기 판정	Inline Gateway가 MAVLink 파싱 후 Fast Block→Rulebase→XGBoost→Meta 순서로 판정한다.	pipeline_trace, verdict, attack_type, latency
3. 승인	ALLOW인 원본 패킷에만 Approval을 생성한다. DROP/QUARANTINE은 Approval을 만들지 않는다.	ALLOW Approval 또는 DROP 사유
4. 전달·차단	Bridge가 Approval의 원본 일치·TTL·방향·Drone ID를 재검증한 뒤 PX4에 1회 전달한다. 차단 패킷은 가능한 경우 Honeypot으로 전송한다.	FORWARDING→DELIVERED/FAILED, HONEYPOT_REDIRECT
5. 분석·복구	기존 async 분석 그래프와 Dashboard/Audit가 증적·대응을 보조하며, Recovery Manager는 별도 안전 상태 전이를 수행한다.	Audit, Influx, POLICY_DECISION, 복구 상태

4. AI 에이전트 아키텍처 및 구현

4-1. AI 에이전트 전체 아키텍처

본 시스템의 AI 에이전트는 공격 AI, 방어 AI, LLM 분석 계층, 정책 통제 계층, Local LLM 기반 Honeypot/Decoy 계층으로 구성된다. 공격 AI는 PX4/MAVLink 상태를 관측하고 허가된 범위 안에서 후보 공격 행동을 선택하며, 방어 AI는 네트워크·센서·임무 상태를 종합해 탐지와 대응 수준을 판단한다. Local LLM 기반 Honeypot/Decoy는 실제 UAV 제어 포트와 분리된 기만 지점에서 MAVLink 유사 응답을 생성하고, 정찰·비인가 GCS 접근·반복 요청 패턴을 방어 판단 증거로 제공한다.[26], [27]

전체 흐름은 공격 AI의 관측→정찰→상황 구성→LLM/fallback 판단→PolicyGuard→MAVLink 실행→피드백 재계획으로 구성된다. 현재 제출 방어본의 운영 명령 경로는 C2/GCS→Bridge·PacketCache→HMAC PacketEnvelope→Inline Gateway(Fast Block→Rulebase→XGBoost→Meta)→ALLOW Approval→Bridge 재검증→PX4이며, DROP/QUARANTINE 패킷은 PX4로 전달되지 않는다. 기존 Suricata-ReAct-Sonnet-Opus-Policy Engine 기반 async 분석 그래프는 분석·대응 증적 계층으로 구분하고, 실시간 승인 경로를 우회하지 않는다.


4-1-1. AI 에이전트 역할 분리 및 통제 장치

구분	AI 에이전트 역할	최종 통제 장치
공격 AI	수동·능동 정찰 결과와 관측 특징을 바탕으로 텔레메트리 요청, 제한 probe, 모드 전환, 후속 시나리오 후보 중 1개를 선택한다.	Policy Guard
방어 AI	네트워크·센서·임무·정책 로그를 종합해 INFO, LOW, MEDIUM, HIGH 대응 수준을 판단한다.	Policy Engine
LLM 분석 계층	비정형 로그와 복합 이벤트의 의미를 해석하고 대응 근거를 생성한다.	confidence, UNKNOWN/ESCALATED, 인간 검토
Honeypot/Decoy	PX4 기반 UAV처럼 보이는 MAVLink 유사 응답을 생성하고, 정찰·비인가 GCS 접근·반복 요청 패턴을 증거로 수집한다.	분리된 decoy 포트 / 정책 엔진 증거 입력

4-2. 공격 AI 에이전트 설계

공격 에이전트는 방어 에이전트와 달리, 서로 다른 프로세스나 LangGraph-CrewAI 같은 별도 오케스트레이션 프레임워크로 분리된 다중 에이전트가 아니다. attack_agent_v3(AI_ATTACK_4.py) 하나의 Python 프로세스 안에서 6개 역할이 순차 호출되는 단일 에이전트 구조다. 이는 설계 누락이 아니라 의도적 선택이다. 관측부터 실행까지의 지연시간을 대회 규정상 시간 제약(포트 확장 단계 30초, 최소 공격 개시 60초) 안에서 최소화해야 하고, 정찰·판단·실행이 동일 소켓·동일 컨텍스트를 공유해야 포트별 상태(target_confidence, repeat_count 등)를 일관되게 추적할 수 있기 때문이다.

그림 2. 공격 에이전트 3계층 구조 (관측·정찰 → 판단·정책검증 → 실행·피드백)



4-2-1. Reconnaissance Module — 관측·정찰 모듈

구성요소	Reconnaissance Module (관측·정찰 모듈)
역할	HEARTBEAT/상태 메시지 수동 관측을 우선 수행하고, 부족 시 제한된 능동 프로브 (COMMAND_LONG, MAV_CMD_REQUEST_MESSAGE)로 전환한다.
입력	포트 후보(config.json 단계별 확장군), passive timeout 설정
출력	raw MAVLink observation, response latency, target_responsive 여부
의사결정 권한	없음 — 관측 결과는 FeatureExtractor로만 전달됨
안전장치	신호 관측 시 이후 포트 확장 단계를 즉시 중단(sustain_after_discovery)
알려진 한계	응답이 지연되는 WAN 환경에서 능동 프로브 소켓이 먼저 닫혀 지연 응답을 놓치고, 뒤늦게 도착한 응답이 반복 ICMP Port Unreachable을 유발하는 사례를 실측 확인

4-2-2. MAVLinkParser / FeatureExtractor — 상태 해석 모듈

구성요소	MAVLinkParser / FeatureExtractor (상태 해석 모듈)
역할	수신 패킷에서 HEARTBEAT·SYS_STATUS·GPS_RAW_INT·COMMAND_ACK 등을 파싱해 target_confidence-detection_risk를 포함한 특징 벡터로 정리한다.
입력	raw packet, active recon 결과, AgentMemory
출력	target_identity, telemetry_state, feedback_state, target_confidence/detection_risk 점수
의사결정 권한	없음 — 판단 계층(LLMBrain)에 컨텍스트만 전달
안전장치	heartbeat_seen·telemetry_complete 등 불리언 근거를 명시적으로 남겨, 후속 계층이 미관측 값을 임의로 가정하지 못하게 함
알려진 한계	target_confidence가 가중합 휴리스틱이라, 새로운 관측 패턴에 대한 자동 재조정 로직은 없음

4-2-3. ContextBuilder / LLMBrain — 판단 제안 모듈

구성요소	ContextBuilder / LLMBrain (판단 제안 모듈 — 유일한 AI 활용 지점)
역할	특징 벡터를 로컬 LLM(Ollama, gemma3:4b)에 전달해 후보 행동과 판단 근거를 제안한다. LLM 미가용 또는 응답 실패 시 결정론적 폴백 트리로 즉시 전환한다.
입력	특징 벡터, 실패 이력, 허용 액션 목록(config.json allowed_actions)
출력	candidate_action, risk_level, reason, expected_observation(JSON)
의사결정 권한	제안만 — 실행 권한 없음. 최종 실행 여부는 PolicyGuard가 결정
안전장치	응답 스키마 미충족 또는 Ollama 호출 예외 시 _fallback_decision()으로 즉시 전환
알려진 한계	LLM 실제 호출 성공 여부가 로그에 상시 구분 표기되지 않아, 실측 사례가 실제 LLM 응답인지 폴백 트리 결과인지 로그만으로는 구분이 어려움

4-2-4. PolicyGuard — 안전 검증

구성요소	PolicyGuard (안전 검증)
역할	candidate_action이 대상 범위·허용 액션·반복 횟수·비행모드·관측된 sys_id 조건을 만족하는지 검증하고, 위반 시 fallback_action으로 강제 대체한다.
입력	decision, context, memory, config.json allowlist
출력	allowed 또는 blocked_replaced 판정(및 _block_reason)
의사결정 권한	사실상 유일한 실행 게이트 — 이 계층을 통과하지 못하면 어떤 candidate_action도 MAVLink로 송신되지 않음
안전장치	제출 기본값은 require_observed_sys_id=false, mode_change_requires_observed_heartbeat=false, control_validation=false이며 ALLOWED_TARGET_IPS는 0.0.0.0 플레이스홀더다. 실제 대상·관측 검증을 활성화한 대회 프로파일과 설정 스냅샷이 필요하다.
알려진 한계	차단 사유가 로그 문자열로만 남고 구조화 집계 없음, 대량 실행 시 통계화가 어려움

4-2-5. ActionTranslator / Executor — 실행 모듈

구성요소	ActionTranslator / Executor (실행 모듈)
역할	검증된 decision을 SET_MODE 또는 시나리오 패턴으로 변환해 실제 MAVLink 프레임 을 송신한다.
입력	검증된 decision(allowed 판정만)
출력	송신 프레임, 실행 결과
의사결정 권한	없음 — PolicyGuard가 승인한 행동만 그대로 실행
안전장치	allowed_flight_modes-target_scope 위반 프레임은 PolicyGuard 단계에서 이미 걸려져 이 계층에 도달하지 않음
알려진 한계	시나리오 스크립트(subprocess) 표준출력이 tail 800자로만 보존되어, 장시간 실행 시 초기 로그가 유실될 수 있음

4-2-6. FeedbackEvaluator / AdaptiveReplanner — 평가 모듈

구성요소	FeedbackEvaluator / AdaptiveReplanner (평가 모듈)
역할	실행 결과와 수신 HEARTBEAT(base_mode/custom_mode)를 대조해 성공·실패·불확실 을 판정하고 AgentMemory를 갱신한다.
입력	실행 결과, 수신 관측값
출력	success/failed/uncertain 판정, repeat_count-recent_failures 갱신
의사결정 권한	없음 — 판정 결과는 다음 사이클의 컨텍스트 입력으로만 사용됨
안전장치	"성공"을 문자열 매칭이 아니라 HEARTBEAT의 custom_mode(main/sub mode) 실제 변 화로 판정
알려진 한계	사이클 초반 uncertain 판정이 다수 발생 — 몇 사이클 안에 success로 수렴하는지에 대 한 통계는 별도로 필요


4-3. 방어 AI 에이전트 설계

방어 파이프라인은 입력 신호를 받아 세 개의 계층(관측 → 판단 → 집행)을 거쳐 최종 대응을 결정한다. 각 계층은 서로 다른 종류의 증거를 생산하거나 해석하며, 정상/즉시대응으로 분기된 경우에는 판단 계층을 거치지 않고 곧바로 집행 계층(Policy Engine)으로 직행한다.

방어 코드에는 기존 LangGraph sim/loop 및 async 분석 경로와, 현재 운영용 fail-closed Inline Gateway 경로가 함께 존재한다. 실제 C2 명령은 Bridge가 원본 패킷의 해시·Drone ID·방향·원본 주소·TTL을 담은 HMAC PacketEnvelope로 등록하고, Inline Gateway가 Fast Block→Rulebase→XGBoost→Meta 순서로 동기 판정한다. ALLOW Approval이 원본과 일치할 때만 PacketCache가 PENDING→FORWARDING→DELIVERED로 전이하며 PX4에 1회 전달한다. Dashboard·Honeypot·비동기 LLM 장애는 Approval을 생성하거나 검증을 우회하지 않는다.

본 방어 에이전트의 "Sonnet Commander"와 "Opus Auditor"는 아키텍처상 역할 구분을 나타내는 설계 명칭으로, 각각 전술 판단 계층과 독립 감사 계층에 해당한다. 실제 구현·검증 단계에서는 각 역할을 특정 Anthropic 모델에 고정하지 않고, 동일한 역할 인터페이스를 통해 Groq 호스팅 모델과 Google Gemini를 백엔드로 연결하여 테스트를 수행하였다. 두 역할이 수행하는 기능적 계약, 즉 대응 제안만 수행하고 직접 집행 권한은 갖지 않으며 독립적으로 판단 근거를 재검토한다는 원칙은 백엔드 모델 종류와 무관하게 동일하게 유지되도록 설계하였다.

그림 3. 방어 에이전트 4계층 구조 (입력 보호·관측 → 동기 판정 → 승인·집행 → 복구·증적)



4-3-1. 관측 계층 - 구성요소

구성요소	역할	입력 → 출력	안전·검증
01 Suricata/Rulebase	알려진 패턴(DAH S01~S12) 규칙·서명 기반 1차 고속 탐지	텔레메트리 JSON(ekf_innov, rate_tx 등) + MAVLink payload → signature name(이진 매칭)	2026-07-02 S02에서 PING_DOS는 탐지했으나 REPLAY 오탐이 차단 경로에 혼입. 현재 modulo-256 수정 후 재검증 필요
02 XGBoost	규칙으로 정의하기 어려운 저강도·복합 이상을 ML 점수화	통신·센서·임무 feature 벡터 → pred + confidence(0~1)	단독 최종 집행 불가 / S10·S11·S13·S16 진단 공백과 S06 오분류에 대한 재학습·회귀시험 필요
03 MAVLink Monitor	sysid 단위 HEARTBEAT·seq·발신원 이상을 시간에 걸쳐 추적	sysid, src_ip, seq → UNAUTHORIZED_GCS_IP, HEARTBEAT_GAP 등	현재 seq 순환 처리와 heartbeat watcher 로그는 코드에 반영됨. S02·S06·S11·S13 동적 재검증 필요
04 MetaDetect	단일 시점에 드러나지 않는 반복·장기 이상 패턴 탐지	sliding window 이상치 누적률 → meta_score(0~1)	S05 진단에서는 XGBoost가 먼저 즉시 탐지하여 Meta 장기 누적 경로가 입증되지 않음
05 MAVLink Decoy Honeypot	PX4 제어 채널과 분리된 디코이 포트에서 정찰·반복 접근을 유인·관측한다. msgid/포트 기반 휴리스틱으로 유형을 추정하고 pymavlink 기반 MAVLink v2 바이너리 응답을 반환한다.	src ip, dst port, msgid, payload len/hex → inferred type, decoy response, honeypot_events.json, InfluxDB event	제어 포트와 격리 / LLM 가짜 값만 제안 / 허용 키만 반영 / 기본값 폴백 / 단독 BLOCK 불가

출처: [3] Suricata IDS Documentation; [4] XGBoost Documentation; [11] XAI and Statistical Analysis for Reliable Intrusion Detection in the UAVIDS-2025 Dataset; [12] From High-Level Types to Low-Level Monitors: Synthesizing Verified Runtime Checkers for MAVLink; [21] Vehicle State Monitoring and Fault Detection System for Unmanned Ground Vehicles using Markov Models; [26] J. Daubert, D. Boopalan, E. Vasilomanolakis, HoneyDrone: A medium-interaction unmanned aerial vehicle honeypot; [27] SoK: Honeypots & LLMs, More Than the Sum of Their Parts

4-3-2. 판단 계층 - ReAct Analyzer - findings·XGBoost 신뢰도 종합 → Sonnet 호출 여부 1차 판별

구성요소	1차 판단 에이전트
역할	기존 async 분석 경로에서 findings와 XGBoost 신뢰도를 해석한다. 운영 Inline Gateway의 ALLOW/DROP 승인 경로에는 포함되지 않는다.
입력	통합된 state (findings, 점수, 신호 전체)
출력	위험 여부 1차 판단, 신뢰도
의사결정 권한	낮음 — 확신도가 높으면 후속 LLM 단계를 생략하여 지연시간 단축
안전장치	"신규 패턴 의심" 신호가 있으면 반드시 구성요소 06까지 도달
실측 근거	2026-07-02 cold start에서 ReAct timeout 사례가 있어 warm-up-timeout 정렬·고아 스레드 정리가 필요하다. 미호출 또는 fallback은 성공 호출과 구분해 기록해야 한다.

4-3-3. 판단 계층 - Sonnet Commander - 전술 대응안 제안, 제안만 수행하며 집행 권한 없음

구성요소	전술 판단 에이전트
역할	복합 상황 해석 및 대응 수준 제안. "신규 패턴 의심" 시 규칙 후보까지 제안. Opus Auditor가 재검토하며 직접 집행 권한은 없다.
입력	통합 state + RAG 참조 컨텍스트
출력	대응 수준 제안(response_level), 신규 패턴 시 규칙 후보 JSON
의사결정 권한	제안만 — 실제 집행 권한 없음. 규칙 후보도 검증 단계(구성요소 08) 통과 필수
안전장치	입력은 "관찰 데이터"로 태깅(프롬프트 인젝션 방지), 출력은 허용 범위 검증 후 반영
실측 근거	신규 패턴 조건 성립 시 실제 LLM 호출을 통해 유효한 규칙 후보(GPS 이상탐지 조건)를 생성한 사례 실측 확인

4-3-4. 판단 계층 - Opus Auditor - Sonnet Commander 제안의 근거·정책 위반 여부를 독립 재검토

구성요소	감사 에이전트
역할	Sonnet Commander의 제안(근거 부족·과잉 대응·정책 위반 여부)을 Constitutional AI 방식으로 독립 재검토한다.
입력	Sonnet의 판단 + 원본 근거
출력	승인/반려 또는 수정 제안
안전장치	이 계층 호출 실패 시에도 파이프라인이 중단되지 않고 다음 단계로 진행 (가용성 우선)
실측 근거	외부 모델 호출 실패 시 생략·fallback되는 가용성 우선 구조는 확인되었다. 따라서 감사 완료를 필수 보안 게이트로 간주하지 않으며, 실제 호출 성공 증적과 분리한다.

4-3-5. 집행 계층 - Policy Engine - 근거 정규화 → mission_impact_score 기반 최종 집행 결정

구성요소	집행 결정자
역할	기존 async 경로에서는 근거를 정책 액션으로 정규화한다. 운영 명령 전달의 최종 게이트는 Inline Gateway verdict와 Approval 재검증이다.
입력	전체 findings, mission_impact_score, LLM·감사 계층의 제안(response_level 등)
출력	최종 대응 수준(mission_impact_score 기준 HARD_BLOCK/NODE_ISOLATE/COMMAND_HOLD/SOFT_LIMIT/ALERT_ONLY, 위협 소멸 시 RECOVER) 및 response_action
의사결정 권한	점수 경로는 누적형이나 Fast Block은 즉시 차단할 수 있다. Inline Gateway는 필수 탐지기 오류·시간 초과에도 fail-closed DROP한다.
안전장치	S01 async HARD_BLOCK은 확인했으나 loop는 NODE_ISOLATE였다. S02는 REPLAY 오탐이 혼입되어 수정 후 동일 모드 재검증이 필요하다.
실측 근거	idle 120초 100% 낮은 수준 유지, 실제 공격 재현 시 약 15초 이내 최고 수위 전환을 복수 근거 결합으로 확인

4-3-6. 집행 계층 - Recovery Manager - 위협 소멸 판단 후 단계적 복구 절차 수행

구성요소	복구 에이전트
역할	GCS 업링크 침묵을 감시하여 NORMAL→HOLD_WAIT→RETREAT 상태를 전이. Policy Engine 과 독립된 이중 안전 계층으로 LOITER-RTL 명령을 발행한다.
입력	신뢰 GCS 업링크 패킷 수신 여부(침묵 지속 시간), 현재 비행 모드, 사전 등록된 안전지대 (safe zone) 좌표
출력	상태 전이 결과(NORMAL/HOLD_WAIT/RETREAT)와 그에 따른 PX4 대응 명령(LOITER 정지 비행, AUTO.RTL 귀환)
의사결정 권한	Policy Engine과 독립적으로 판단·명령을 발행 — 업링크 침묵이라는 별도 조건 충족 여부만으로 동작하는 이중 안전 계층
안전장치	HOLD_WAIT/RETREAT 상태에서는 bridge gate가 닫혀, 침묵 이후 뒤늦게 수신되는 GCS 명령(공격자에 의해 오염되었을 가능성이 있는 명령 포함)이 PX4로 전달되지 않도록 차단
실측 근거	SITL 환경에서 신뢰 GCS 업링크를 인위적으로 끊었을 때 NORMAL→HOLD_WAIT→RETREAT 상태 전이와 LOITER→AUTO.RTL 명령 발행이 설계대로 일어나는 것을 확인하였다.

출처: [19] MARS: Defending Unmanned Aerial Vehicles From Attacks on Inertial Sensors with Model-based Anomaly Detection and Recovery [20] PX4 Safety/Failsafe Configuration

4-3-7. 정책 점수 체계 — Policy Engine 기반 점수 체계

기존 async 분석 경로의 Policy Engine v1.1은 각 AI·비AI 근거를 mission_impact_score(0~100)로 정규화하여 대응 액션으로 변환한다. 다만 REPLAY_ATTACK·SYSID 위장 등 Fast Block 항목과 운영 Inline Gateway의 DROP 판정은 점수 누적 전에 즉시 차단될 수 있으므로, 모든 차단이 복수 근거 누적을 거친다고 표현하지 않는다. [24]

ATT&CK 자체는 심각도 등급을 제공하지 않으므로, 기법 연계는 분류·추적에만 사용한다. 점수는 임무 영향·탐지 신뢰도·복수 근거 결합을 반영한 팀 내부 정책값이다. 비인가 MAVLink 메시지는 Unauthorized Message(T1692) 계열에 연계하고, GPS 스푸핑은 임무 영향을 기준으로 별도 가중한다. [5]

근거	점수
high-risk 유형 (MISSION_HIJACKING 등)	+40
XGBoost - GPS_SPOOFING / MAVLINK_REPLAY	+30
GPS_SPOOFING	+25
Stealth / poison / heartbeat gap / Suricata signature / PING_DOS Attack	+20
stale telemetry / meta_score ≥ 0.60	+15
availability < 0.8 / XGBoost score ≥ 0.95	+10

4-3-8. 대응 기준 — mission_impact_score 구간별 대응 수준 매핑

점수 구간(mission_impact_score)	대응 수준	실제 동작
80점 이상	HIGH HARD_BLOCK	iptables로 10분간 완전 차단
40~79점	60~79 NODE_ISOLATE / 40~59 COMMAND_HOLD	노드 격리 또는 TTL 60초 차단·QGC 전달 억제; 반복 시 HIGH 승격
20~39점	LOW SOFT_LIMIT	QGC 전달만 억제(bridge 미차단); 10분 내 3회면 MEDIUM 승격
1~19점	INFO ALERT_ONLY	전달 허용 및 로그 누적; 다음 틱 meta_score +0.05 가산

점수 기반 5개 집행 액션과 별도로, 명시적 Fast Block 항목은 fail-closed 원칙에 따라 즉시 DROP/HARD_BLOCK될 수 있다.

4-3-9. 관측 계층 실측 요약 — SITL 실측 기반 관측 계층 성능 요약

시나리오	핵심 관측 신호	검증 결과
idle (120s)	XGB·MetaDetect 임계 미만	2026-07-02 async 진단에서 ALERT_ONLY 유지
S02 (Ping_DoS)	Rulebase PING_DOS, XGB Normal(0.118), REPLAY false positive	HARD_BLOCK은 발생했으나 오경로. modulo-256 수정 후 재검증 필요
S01 (GPS spoofing)	XGB GPS_Spoofing 0.990~1.000, Rulebase GPS 이상	async=HARD_BLOCK, loop=NODE_ISOLATE로 모드 불일치
전체 진단	S01~S17 동적 진단 + 현재 S01~S21 파일 존재 확인	S10-S11-S13-S16 공백, S06 오분류, S08 부분; 21개 전수 회귀시험 필요

4-3-10. 아키텍처 검증 결과 요약 — 3계층 파이프라인 통합 동작 검증 결과

검증 대상	검증 결과 예시
idle (120s)	[XGB] Normal, [MetaDetect] 임계 미만 → ALERT_ONLY 유지(2026-07-02 async 진단)
S02 Ping_DoS	[Rulebase] PING_DOS / [XGB] Normal(0.118) / [MAVLink] REPLAY(false+) → HARD_BLOCK. 당시 차단은 오탐 혼입 경로
S01 GPS spoofing	[async] XGB GPS_Spoofing(0.990~1.000) → fast_decision → HARD_BLOCK / [loop] score=65 → NODE_ISOLATE
현재 코드 정적 확인	MAVLink seq expected=(last_seq+1)%256, heartbeat watcher 결과·경고 로그, fail-closed Inline Gateway·Approval·PacketCache 구현 확인
재검증 필요	S02-S06-S10-S11-S13-S16 및 S14/S15 배포 동기화 포함 S01~S21 동일 async/inline 환경 전 수 회귀시험

5. 시나리오 구현 및 검증 증적

5-1. 공격 시나리오 구현 증적

그림 4. 공격 성공 - 대상 및 포트 선택

```
[TARGET SCOPE]
1. Single target
2. Multiple targets
3. Exit
Select: 1
Target IP: 192.168.1.100

[ATTACK MODE]
1. Default AI auto attack
2. SET_MODE
3. CVE attack
4. Scenario attack
Select: 1

[PORT MODE]
1. Auto port expansion from config.json
   14540-14543 -> 14550-14552 -> 18570-18573 -> 14580-14583
2. 14540-14543
3. 14550-14552
4. 18570-18573
5. 14580-14583
6. Manual input, e.g. 1234 or 1234-4567 or 14540,14541,14550-14552
Select: 1
Duration seconds [180]:
LLM model [gemma3:4b]:

[RUN CONFIRM]
Target: --target 192.168.1.100
Attack mode: Default AI auto attack
Port mode: auto port expansion from config.json
```

그림 5. 공격 성공 - 공격 에이전트 실행 중 로그

```
[Cycle 1] LLM decision: mode_change_attempt
[Cycle 1] Policy Guard: allowed
[ActionTranslator] mode_change_attempt -> SET_MODE ScenarioAction
[Cycle 1] Selected SET_MODE target_mode=LAND base_mode=5 custom_mode=100925440 sys_id=1
[Cycle 1] LLM decision: mode_change_attempt
[Cycle 1] Policy Guard: allowed
[ActionTranslator] mode_change_attempt -> SET_MODE ScenarioAction
[Cycle 1] Selected SET_MODE target_mode=LAND base_mode=5 custom_mode=100925440 sys_id=4
[Executor] SET_MODE selected target_mode=LAND sys_id=4 component_id=1 base_mode=5 custom_mode=100925440 port=14543
[Cycle 1] LLM decision: mode_change_attempt
[Cycle 1] Policy Guard: allowed
[ActionTranslator] mode_change_attempt -> SET_MODE ScenarioAction
[Cycle 1] Selected SET_MODE target_mode=LAND base_mode=5 custom_mode=100925440 sys_id=3
[Executor] SET_MODE selected target_mode=LAND sys_id=3 component_id=1 base_mode=5 custom_mode=100925440 port=14542
[Cycle 1] Executor: execute SET_MODE
```

그림 6. 공격 성공 - 공격 에이전트 실행 후 로그

```
## 1. 공격 메타 정보
- 번호 : `AI_ATTACK_4`
- 시간 : `2026-07-09T22:45:12+09:00`
- Target IP: `34.56.5.42`
- Evidence directory: `logs/20260709_224150`

## 2. 타겟 시스템 정보

### Observed
- 검색 포트 : `14540, 14541, 14542, 14543`
- Target responsive: `false`
- Observed protocol evidence: `[ "확인 불가" ] x12`
- Payload hex records: `8`
- Bytes sent: `144`
```

5-2. AI 방어 시나리오 구현 증적

방어 측 증적은 현재 Inline Gateway의 ALLOW/DROP-Approval-PacketCache 흐름과, 기존 async 분석 경로의 Suricata-Rulebase-XGBoost-MetaDetect-Policy Engine 결과를 구분해 해석한다. 그림의 iptables 차단과 대시보드는 특정 실행 사례의 증거이며, 2026-07-02 진단에서 확인된 탐지 공백과 모드별 대응 차이를 함께 고려한다. Honeypot 이미지는 UDP 14543~14549에서 MAVLink 바이너리 응답과 llm_used true/false 폴백을 확인하는 기만 계층 증거다.

그림 7. 복구 - UAV 안전 상태 전환 증적

```
[Observe] COMMAND_ACK command=176 result=0
[Observe] sysid=1 mode=AUTO.LOITER base=157
[RecoveryJSON] {"baseline_mode": "custom=393216 main=6 sub=0",
, "before_mode": "AUTO.LOITER", "event": "RECOVERY_DECISION",
"execute": true, "reason": "mode_changed:custom=393216 main=
6 sub=0->AUTO.LOITER", "recovery_point": {"alt_rel_m": 30.0,
"lat": 47.3978, "lon": 8.5457, "radius_m": 8.0}, "selected_cu
stom_mode": 50593792, "selected_mode": "GOTO", "selected_stra
tegy": "goto", "sysid": 1, "ts": 1783607996.613801}
[RecoveryExecutor] sysid=1 DO_REPOSITION -> lat=47.3978000 lo
n=8.5457000 alt=30.0m(rel)
[Observe] COMMAND_ACK command=192 result=0
```

그림 8. 허니팟 - Decoy 접근 및 탐지 로그

```
ck 기본값 사용 (attack=HEARTBEAT_GAP)
2026-07-09 13:25:19,571 [INFO] uav_defense.honeypot: [Honeypot] UDP
→ port 14546 | attack=MISSION_HIJACKING | binary MAVLink(13B) sent |
llm_used=False
2026-07-09 13:25:19,572 [INFO] uav_defense.honeypot: [Honeypot] UDP
246:41066 → port 14546 | attack=HEARTBEAT_GAP | binary MAVLink(21B) sent | llm
_used=False
2026-07-09 13:25:24,172 [INFO] uav_defense.honeypot: [Honeypot][LLM] Ollama 값
생성 (attack=ROGUE_GCS)
2026-07-09 13:25:24,173 [INFO] uav_defense.honeypot: [Honeypot] UDP
246:43412 → port 14544 | attack=ROGUE_GCS | binary MAVLink(21B) sent | llm_use
d=True
2026-07-09 13:26:04,028 [INFO] uav_defense.honeypot: [Honeypot][LLM] Ollama 값
생성 (attack=ROGUE_GCS)
2026-07-09 13:26:04,032 [INFO] uav_defense.honeypot: [Honeypot] UDP
246:54980 → port 14543 | attack=ROGUE_GCS | binary MAVLink(21B) sent | llm_use
d=True
2026-07-09 13:26:20,627 [WARNING] uav_defense.honeypot: [Honeypot][Ollama] 동
```

그림 9. 공격 실행 화면 - Ping_DoS 시나리오 실행 로그

```
limjh7200@attack-server:~$ cd /home/limjh7200/uav_attack_new/scenarios
python3 scenario_2_ping_dos.py --target 10.178.0.7 --port 14551
```

Scenario 2 - Ping DoS (MAVLink Binary)
HEARTBEAT 폭탄 → rate_tx 폭증

```
타겟 : ██████████ 14551 | 1000pps x 30.0s
전송 시작 ...
[500] 전송
[1000] 전송
[1500] 전송
[2000] 전송
[2500] 전송
[3000] 전송
```

그림 10. 탐지→판정→iptables 차단 로그

```
limjh7200@defense-server-gpu:~$ cd ~/uav_defense_v2_new
tail -f logs/main_async_a.out | grep -E --color=always "action=|UNAUTHORIZED_GCS_IP|ROGUE_GCS|RealBlock|PolicyEngine"
```

```
2026-07-10 22:41:19,766 [INFO] uav_defense.data: [MAVLink_v2] 이슈: ['UNSIGNED_PACKET', 'UNAUTHORIZED_GCS_IP']
2026-07-10 22:41:19,788 [WARNING] uav_defense.data: [Branch] MAVLINK_FAST_BLOCK src=10.178.0.5 type=UNAUTHORIZED_GCS_IP → immediate (LLM 스킵)
2026-07-10 22:41:20,852 [INFO] uav_defense.policy: [PolicyEngine] final=ROGUE_GCS score=80 action=HARD_BLOCK latency=1.3ms breakdown={'UNAUTHORIZED_GCS_IP': 40, 'ROGUE_GCS': 40}
2026-07-10 22:41:20,866 [INFO] uav_defense.action: [RealBlock] TTL 자동해제 스레드 시작 (주기=10s)
2026-07-10 22:41:20,882 [WARNING] uav_defense.action: [RealBlock] ██████████ - iptables DROP 적용 (TTL=600s)
2026-07-10 22:41:20,882 [INFO] uav_defense.action: [Block] attacker_UNAUTHORIZED_GCS_IP → HARD_BLOCK, 가용성: 95.0%
2026-07-10 22:41:20,969 [INFO] uav_defense.action: [Orchestrator] 틱 3755 완료 | branch=immediate action=HARD_BLOCK impact=80 avail=95.0% meta=0.387 corr=tick-3755-a377f7ad
2026-07-10 22:41:20,969 [INFO] uav_defense: [AsyncLoop] 틱 3755 immediate 완료: action=HARD_BLOCK level=HARD_BLOCK
2026-07-10 22:41:20,974 [INFO] uav_defense.data: [MAVLink_v2] 이슈: ['UNSIGNED_PACKET', 'UNAUTHORIZED_GCS_IP', 'SEQ_GAP']
2026-07-10 22:41:20,974 [WARNING] uav_defense.data: [Branch] MAVLINK_FAST_BLOCK src=██████████ type=UNAUTHORIZED_GCS_IP → immediate (LLM 스킵)
2026-07-10 22:41:21,004 [INFO] uav_defense.policy: [PolicyEngine] final=ROGUE_GCS score=80 action=HARD_BLOCK latency=0.11ms breakdown={'UNAUTHORIZED_GCS_IP': 40, 'ROGUE_GCS': 40}
2026-07-10 22:41:21,015 [INFO] uav_defense.action: [Orchestrator] 틱 3756 완료 | branch=immediate action=HARD_BLOCK impact=80 avail=100.0% meta=0.470 corr=tick-3756-c1faed14
2026-07-10 22:41:21,015 [INFO] uav_defense: [AsyncLoop] 틱 3756 immediate 완료: action=HARD_BLOCK level=HARD_BLOCK
```


그림 11. 방어 에이전트 대시보드 탐지 현황



그림 12. 실제 iptables DROP 규칙 확인

```
limjh7200@defense-server-gpu:~/uav_defense_v2_new$ sudo iptables -L INPUT -n --line-numbers
Chain INPUT (policy ACCEPT)
num target prot opt source destination
1 DROP all -- 10.178 0.0.0.0/0
```

6. 결론 및 향후 계획

6-1. 결론

본 프로젝트는 PX4 SITL 기반 다중 UAV 환경을 대상으로, 공격 AI 에이전트와 방어 AI 에이전트가 실제 MAVLink 패킷과 기체 상태 변화를 근거로 상호작용하는 통제형 AI 공방전 구조를 설계·구현하였다.

공격 AI 에이전트는 수동 관측과 제한적 능동 정찰 결과를 바탕으로 후보 행동을 제안하고 PolicyGuard 를 거쳐 실행한다. 다만 제출 기본 config.json 은 ALLOWED_TARGET_IPS=0.0.0.0 플레이스홀더, require_observed_sys_id=false, mode_change_requires_observed_heartbeat=false, control_validation=false 이므로, 제출 상태만으로 대상·관측 기반 안전 검증이 모두 활성화되었다고 볼 수 없다. 실전 시연 전 실제 허가 IP.sysid 를 고정하고 관측 검증 옵션을 활성화한 설정 스냅샷을 증적으로 남겨야 한다.

현재 방어의 핵심 집행 경로는 fail-closed Inline Gateway 다. Bridge 가 승인 대기 패킷을 PacketCache 에 등록하고, Fast Block→Rulebase→XGBoost→Meta 동기 판정에서 ALLOW 된 패킷에만 Approval 을 발급·재검증한 뒤 PX4 로 전달한다. ReAct Analyzer·Sonnet Commander·Opus Auditor·Policy Engine 은 기존 async 분석 및 대응 증거 경로에서 보조 판단과 대응 액션을 생성하며, 운영 승인 경로를 우회하는 권한은 없다.

또한 Recovery Manager 를 Policy Engine 과 독립된 안전 계층으로 구성하여 신뢰 GCS 업링크 침묵 시 NORMAL → HOLD_WAIT → RETREAT → SAFE_AT_ZONE 상태 전이를 수행하도록 설계하였다. 이를 통해 공격 탐지와 네트워크 차단뿐 아니라 LOITER, AUTO.RTL 등을 활용한 임무 안전 복구까지 하나의 방어 흐름으로 연결하였다.

본 프로젝트의 핵심 차별성은 LLM 을 최종 실행자로 두지 않고 공격 측 PolicyGuard 와 방어 측 Inline Gateway·Approval 검증으로 권한을 분리한 점이다. 제출 코드에는 fail-closed·무결성·중복 전달 방지 단위 테스트가 포함되어 있다. 다만 검토 환경의 전체 unittest 는 76 개 중 71 개가 통과하고 pymavlink-python-dotenv 미설치로 5 개 모듈이 수집 단계에서 실패했으므로, 의존성 고정 환경에서 전체 회귀시험과 실제 PX4 end-to-end 재검증이 필요하다.

최종적으로 본 프로젝트는 공격 에이전트의 관측·판단·실행·피드백 구조와 방어 에이전트의 동기식 승인 게이트 및 비동기 분석 구조를 함께 구현하였다. 다만 2026-07-02 진단에서 S10·S11·S13·S16 탐지 공백, S06 오분류, S08 부분 일치, S01 의 async/loop 대응 차이가 확인되었다. 현재 코드 보완 사항을 반영한 21 개 시나리오 전수 회귀시험과 동일 correlation_id·시간축의 PX4/QGC 증적을 완료하는 것이 다음 검증 단계다.

6-2. 향후 계획

향후에는 단순히 공격 시나리오를 추가하는 수준을 넘어, AI가 운용 환경과 기체 상태를 스스로 인식하고 공격·방어 결과를 누적 반영하여 전략을 동적으로 조정하는 자율형 공방전 플랫폼으로 발전시키는 것을 목표로 한다.[15], [16], [18] 또한 UAV 중심의 현재 구조를 UGV 및 다양한 무인체계로 확장하고, Vision AI 기반 센서 공격과 MAVLink·네트워크 공격을 결합한 복합 시나리오를 검증함으로써 실제 방산 환경에 가까운 AI 기반 사이버 공방전 체계를 구현하고자 한다.[7], [8], [17], [19], [21]

6-2-1. 향후 계획

항목	내용
AI 기반 적응형 Hybrid 공격 고도화	공격 결과, 방어 반응, 실패 이력을 기반으로 다음 공격 시나리오를 자동 재선택·조합하도록 고도화
AI 기반 자율 공격면(Attack Surface) 탐색	MAVLink 서비스, 시스템 ID, 비행 모드, 응답 패턴을 기반으로 공격 가능 지점을 자동 식별
Cross-Domain Hybrid Attack	MAVLink, 네트워크 트래픽, GCS 링크, 센서·상태 정보를 결합한 복합 공격 시나리오 설계
멀티 UAV/UGV 군집 검증	다수 기체 환경에서 일부 기체 공격·격리 시 나머지 기체의 임무 지속성과 방어 확장성 검증
UGV 환경 확장	UAV 중심 구조를 UGV의 통신, 센서, 주행 제어 특성에 맞게 확장
네트워크 계층 실제 집행 확장	대상 IP·sysid·heartbeat 관측을 강제하는 대회용 공격 설정 프로파일을 고정하고 실행 전 설정 스냅샷을 증적으로 보존
적응형 규칙의 정책 반영	동일 inline/async 모드에서 S01~S21 전수 회귀시험을 수행하고 탐지 경로·오탐·미탐·지연시간·PX4/QGC 상태를 correlation_id로 연결

7. 참고문헌

- [1] MAVLink Protocol Documentation, <https://mavlink.io>
- [2] PX4 Autopilot Documentation, <https://docs.px4.io>
- [3] Suricata IDS Documentation, <https://suricata.io>
- [4] XGBoost Documentation, <https://xgboost.readthedocs.io>
- [5] MITRE ATT&CK for ICS, <https://attack.mitre.org/matrices/ics>
- [6] MITRE ATLAS, <https://atlas.mitre.org>
- [7] UAV 대상 AI 보안 공격 현황 및 대응 방안 연구.
- [8] 군용 드론/UAV에 대한 AI 적용과 사이버보안 취약요소에 관한 동향 연구
- [9] 지능화 전장에서 인공지능 기반 공격용 군집드론 운용 방안. 군집 패턴
- [10] 인공지능(AI) 기반 공격용 드론의 효과적 전력화 방안에 관한 연구
- [11] XAI and Statistical Analysis for Reliable Intrusion Detection in the UAVIDS-2025 Dataset: From Tree to Hybrid and Tabular DNN Ensembles, <https://arxiv.org/abs/2605.13922>
- [12] From High-Level Types to Low-Level Monitors: Synthesizing Verified Runtime Checkers for MAVLink, <https://arxiv.org/abs/2604.03886>
- [13] A Framework for Hybrid Collective Inference in Distributed Sensor Networks, <https://arxiv.org/abs/2603.28778>
- [14] Digital Twin Enabled Simultaneous Learning and Modeling for UAV-assisted Secure Communications with Eavesdropping Attacks, <https://arxiv.org/abs/2603.22753>
- [15] Hierarchical Observe-Orient-Decide-Act Enabled UAV Swarms in Uncertain Environments: Frameworks, Potentials, and Challenges, <https://arxiv.org/abs/2603.09191>
- [16] Agentic AI-Driven UAV Network Deployment: An LLM-Enhanced Exact Potential Game Approach, <https://arxiv.org/abs/2603.07456>
- [17] When Connectivity Is Not Enough: Cross-Layer Attacks on UAV C2 over 5G, <https://arxiv.org/abs/2603.04662>
- [18] Multi-Agent Collaborative Intrusion Detection for Low-Altitude Economy IoT: An LLM-Enhanced Agentic AI Framework, <https://arxiv.org/abs/2601.17817>
- [19] MARS: Defending Unmanned Aerial Vehicles From Attacks on Inertial Sensors with Model-based Anomaly Detection and Recovery, <https://arxiv.org/abs/2505.00924>
- [20] PX4 Safety/Failsafe Configuration, <https://docs.px4.io/main/en/config/safety>
- [21] Vehicle State Monitoring and Fault Detection System for Unmanned Ground Vehicles using Markov Models, <https://roboticsproceedings.org/rss09/p14.pdf>
- [22] MAVSec: Securing the MAVLink Protocol for Ardupilot/PX4 Unmanned Aerial Systems, <https://arxiv.org/abs/1905.00265>
- [23] MUVIDS: False MAVLink Injection Attack Detection in Unmanned Vehicles, https://www.ndss-symposium.org/wp-content/uploads/autosec2021_23036_paper.pdf
- [24] Runtime Assurance for Autonomous Systems, https://finkbeiner.groups.cispa.de/_assets/paper/CJnzzFT5.pdf
- [25] PX4 Simulation - Default PX4 MAVLink UDP Ports, <https://docs.px4.io/v1.16/en/simulation/>
- [26] J. Daubert, D. Boopalan, E. Vasilomanolakis, HoneyDrone: A medium-interaction unmanned aerial vehicle honeypot, 2018 IEEE/IFIP NOMS, <https://doi.org/10.1109/NOMS.2018.8406315>
- [27] SoK: Honeypots & LLMs, More Than the Sum of Their Parts?, <https://arxiv.org/abs/2510.25939>
- [28] Stable Agentic Control: Tool-Mediated LLM Architecture for Autonomous Cyber Defense,

<https://arxiv.org/abs/2605.03034>

[29] Securing LLM-based agents against cyberattacks: a comprehensive survey on attack techniques and defense strategies, Journal of Computer Virology and Hacking Techniques (2026),

<https://doi.org/10.1007/s11416-026-00622-3>

[30] CVE-2026-32724 Detail, National Vulnerability Database, <https://nvd.nist.gov/vuln/detail/CVE-2026-32724>

[31] CVE-2026-32709 Detail, National Vulnerability Database, <https://nvd.nist.gov/vuln/detail/CVE-2026-32709>

[32] CVE-2026-1579 Detail, National Vulnerability Database, <https://nvd.nist.gov/vuln/detail/CVE-2026-1579>

[33] Associated Press, "Ukrainian midrange drones reshape the battlefield by targeting Russian supply lines," 2026. <https://apnews.com/article/c0909dbcc38d597142d1c662979c8406>

[34] Associated Press, "Ukrainian drones batter Russian oil facilities and set more oil tankers ablaze," 2026. <https://apnews.com/article/6cb5602f1cf309533ed0cf5c734e19d8>

[35] Business Insider, "NATO can't just stockpile millions of drones and hope they'll still matter in the next war, officials warn," 2026. <https://www.businessinsider.com/nato-cant-stockpile-lots-drones-maybe-out-date-next-war-2026-7>